

Aprimoramento de Metaheurísticas para Otimização da Cadeia de Suprimentos de Pistache

1st Raissa Gonçalves Diniz

Operations Research and Complex Systems Laboratory
Universidade Federal de Minas Gerais
Belo Horizonte, Brasil
raissagd@ufmg.br

2nd André Costa Batista

Departamento de Engenharia Elétrica
Universidade Federal de Minas Gerais
Belo Horizonte, Brasil
andre-costa@ufmg.br

Resumo—As cadeias de suprimentos desempenham um papel fundamental na indústria agrícola, especialmente no caso de culturas de alto valor, como o pistache, onde uma gestão eficiente pode impulsionar o crescimento econômico e promover a sustentabilidade. Embora pesquisas anteriores tenham explorado estratégias de otimização para essas cadeias, a maioria dos estudos concentra-se no uso de algoritmos populacionais para enfrentar esses desafios. Neste trabalho, propomos a aplicação do algoritmo de Busca em Vizinhança Variável (Variable Neighborhood Search - VNS) e avaliamos seu desempenho em comparação com uma metaheurística populacional, especificamente o Algoritmo Genético (Genetic Algorithm - GA). Os resultados mostram que o VNS apresenta consistentemente um desempenho superior ao GA, tanto em termos de eficiência computacional quanto de qualidade das soluções, especialmente em instâncias de maior porte. Esses achados destacam o potencial do método proposto como uma abordagem eficaz para a otimização de cadeias de suprimentos.

Index Terms—Otimização de Cadeias de Suprimentos, Metaheurísticas, Busca em Vizinhança Variável, Sustentabilidade.

I. INTRODUÇÃO

A agricultura desempenha um papel fundamental no desenvolvimento econômico, contribuindo não apenas para a segurança alimentar, mas também para as exportações e o crescimento industrial. Entre as culturas de alto valor, os pistaches se destacam no comércio internacional, com os Estados Unidos, a Turquia e o Irã liderando a produção global [22]. A gestão eficiente de cadeias de suprimentos é essencial para manter a qualidade dos produtos, reduzir impactos ambientais e garantir uma distribuição eficaz. Um dos principais desafios na produção de pistache é o manejo dos subprodutos, como cascas e resíduos da polpa, que, se descartados de forma inadequada, podem comprometer a qualidade do solo e gerar riscos à saúde devido à contaminação por aflatoxinas produzidas por fungos [26]. Estratégias sustentáveis de gestão de resíduos, como compostagem e produção de biogás, têm sido exploradas para mitigar esses problemas, conforme discutido por [6].

Falhas na cadeia de suprimentos exercem impacto significativo tanto na qualidade dos produtos quanto nas operações comerciais. Estudos anteriores, como o de [2], investigaram técnicas de otimização baseadas em Algoritmos Genéticos (Genetic Algorithm - GA) e outras meta-heurísticas evolucionárias para a logística do pistache. No entanto, muitas

dessas comparações se baseiam apenas nas melhores soluções encontradas, sem uma validação estatística robusta que comprove a superioridade dos resultados. Além disso, ainda há debate sobre a influência real das diferenças entre meta-heurísticas bioinspiradas na qualidade das soluções obtidas.

Neste estudo, propõe-se a otimização da cadeia de suprimentos do pistache utilizando a metaheurística Busca em Vizinhança Variável (Variable Neighborhood Search - VNS), que é amplamente reconhecida por sua eficácia na resolução de problemas combinatórios complexos com baixa necessidade de parametrização. O modelo matemático utilizado é baseado na formulação mista linear proposta por [2] para a logística direta e reversa, que foca na minimização de custos e na redução de impactos ambientais por meio do reaproveitamento de subprodutos. A principal contribuição deste trabalho está na aplicação do VNS a esse modelo, avaliando seu desempenho em comparação com o Algoritmo Genético (GA). Os resultados demonstram que o VNS apresenta vantagens em termos de qualidade das soluções e tempo computacional. Embora o uso de metaheurísticas para otimização de cadeias de suprimentos não seja novo, a aplicação específica do VNS neste contexto oferece uma alternativa interessante e promissora, especialmente em problemas de maior escala e complexidade. Essa abordagem pode contribuir para o aprimoramento da eficiência na gestão de cadeias de suprimentos agrícolas, mantendo a sustentabilidade e otimizando os custos operacionais.

A estrutura deste artigo organiza-se da seguinte forma: a Seção II apresenta a definição do problema, descrevendo a estrutura da cadeia de suprimentos e os objetivos de otimização. A Seção III detalha a abordagem heurística, explicando a metodologia VNS e sua implementação. A Seção IV compara os resultados experimentais entre VNS e GA. Por fim, a Seção V apresenta as principais conclusões e direções para pesquisas futuras.

II. DEFINIÇÃO DO PROBLEMA

A rede proposta por [2], conforme ilustrado na Figura 1, é composta por produtores, centros de processamento, fábricas de pistache, centros de extração de óleo, centros de compostagem e clientes. Os pistaches são transportados dos pomares para os centros de processamento, onde são transformados em pistaches de casca aberta, sementes cruas e resíduos.

Esses produtos são então enviados para fábricas, centros de extração de óleo e centros de compostagem, respectivamente. Os pistaches de casca aberta são torrados, embalados e entregues aos clientes, enquanto o óleo de pistache é fornecido aos clientes de óleo e fábricas de cosméticos. Os resíduos são convertidos em composto para distribuição. Embora o composto seja devolvido aos produtores, idealmente criando um sistema de circuito fechado, o modelo matemático não estabelece uma conexão direta entre os clientes de composto e os produtores que fornecem pistaches aos centros de processamento. Estritamente falando, o modelo matemático de fluxo não implementa um circuito fechado. Em vez disso, interpreta o fluxo de composto para seus respectivos clientes como um feedback, mesmo que esses clientes não estejam necessariamente vinculados às variáveis associadas aos produtores. Abordagens semelhantes foram adotadas em outros estudos ([11], [19], [20]), e a implementação rigorosa de um circuito de feedback poderia ser uma direção promissora para pesquisas futuras.

O problema linear misto visa minimizar os custos totais (1), incluindo custos de abertura, produção e transporte, sob as seguintes restrições de capacidade e demanda, não tolerando escassez (ver mais detalhes sobre as variáveis na Tabela 5 de [2]):

$$\min z_1 + z_2 + z_3 \quad (1)$$

$$\text{s.t.: } \sum_{j=1}^J X_{ij} \leq Cpa_i, \quad \forall i \in I \quad (2)$$

$$\sum_{i=1}^I X_{ij} \leq Cpu_j \times U_j, \quad \forall j \in J \quad (3)$$

$$\sum_{e=1}^E Ow_{eq} + \sum_{j=1}^J Gw_{jq} \leq Cpy_q \times Y_q, \quad \forall q \in Q \quad (4)$$

$$\sum_{j=1}^J Go_{jk} \leq Cpw_k \times W_k, \quad \forall k \in K \quad (5)$$

$$\sum_{j=1}^J Gr_{je} \leq Cpr_e \times R_e, \quad \forall e \in E \quad (6)$$

$$\sum_{e=1}^E Oen_2 \leq Cpv_s \times V_s, \quad \forall s \in S \quad (7)$$

$$\sum_{k=1}^K Go_{jk} + \sum_{e=1}^E Gr_{je} + \sum_{q=1}^Q Gw_{jq} \leq \sum_{i=1}^I X_{ij}, \quad \forall j \in J \quad (8)$$

$$\sum_{k=1}^K Go_{jk} = (1 - \beta) \sum_{i=1}^I X_{ij} \theta_1, \quad \forall j \in J \quad (9)$$

$$\sum_{e=1}^E Gr_{je} = (1 - \beta) \sum_{i=1}^I X_{ij} \theta_2, \quad \forall j \in J \quad (10)$$




Figura 1: Cadeia de Suprimentos de Pistache proposta

$$\sum_{q=1}^Q Gw_{jq} = \sum_{i=1}^I X_{ij} \theta_3, \quad \forall j \in J \quad (11)$$

$$\theta_1 + \theta_2 + \theta_3 = 1 \quad (12)$$

$$\sum_{n_1=1}^{N_1} P_{kn_1} \leq \sum_{j=1}^J Go_{jk} \times \gamma_k, \quad \forall k \in K \quad (13)$$

$$\sum_{n_2=1}^{N_2} Oen_2 + \sum_{s=1}^S Oc_{es} \leq \sum_{j=1}^J Gr_{je} \times (1 - \lambda), \quad \forall e \in E \quad (14)$$

$$\sum_{q=1}^Q Ow_{eq} \leq \sum_{j=1}^J Gr_{je} \times \lambda, \quad \forall e \in E \quad (15)$$

$$\sum_{n_3=1}^{N_3} L_{sn_3} \leq \sum_{e=1}^E Oc_{es} \times \gamma_s, \quad \forall s \in S \quad (16)$$

$$\sum_{m=1}^M D_{qm} \leq \left(\sum_{j=1}^J Gw_{jq} + \sum_{e=1}^E Ow_{eq} \right) \times \gamma_q, \quad \forall q \in Q \quad (17)$$

$$\sum_{k=1}^K P_{kn_1} \geq Dp_{n_1}, \quad \forall n_1 \in N_1 \quad (18)$$

$$\sum_{e=1}^E Oen_2 \geq Du_{n_2}, \quad \forall n_2 \in N_2 \quad (19)$$

$$\sum_{s=1}^S L_{sn_3} \geq Ds_{n_3}, \quad \forall n_3 \in N_3 \quad (20)$$

$$\sum_{q=1}^Q D_{qm} \leq Dc_m, \quad \forall m \in M \quad (21)$$

- A função objetivo (1) minimiza os custos totais da cadeia de suprimentos, incluindo custos de abertura, transporte e produção. Os custos são divididos em três componentes: z_1 (22), z_2 (23), e z_3 (24), que representam os custos de abertura de instalações, transporte e produção, respectivamente, conforme mostrado nas seguintes equações:

$$z_1 = \sum_{j=1}^J Fu_j \cdot U_j + \sum_{q=1}^Q Fy_q \cdot Y_q + \sum_{k=1}^K Fw_k \cdot W_k + \sum_{e=1}^E Fre \cdot Re + \sum_{s=1}^S Fvs \cdot Vs \quad (22)$$

$$z_2 = \sum_{i=1}^I \sum_{j=1}^J CI_i \cdot X_{ij} + \sum_{j=1}^J \sum_{k=1}^K Cu_{1j} \cdot Go_{jk} + \sum_{j=1}^J \sum_{e=1}^E Cu_{2j} \cdot Gr_{je} + \sum_{q=1}^Q \sum_{m=1}^M Cy_q \cdot D_{qm} + \sum_{k=1}^K \sum_{n_1=1}^{N_1} Cw_k \cdot P_{kn_1} + \sum_{e=1}^E Cre \cdot \left(\sum_{n_2=1}^{N_2} O_{en_2} + \sum_{s=1}^S Oc_{es} \right) + \sum_{s=1}^S \sum_{n_3=1}^{N_3} Cv_s \cdot L_{sn_3} \quad (23)$$

$$z_3 = \sum_{i=1}^I \sum_{j=1}^J CX_{ij} \cdot X_{ij} + \sum_{j=1}^J \sum_{k=1}^K CK_{jk} \cdot Go_{jk} + \sum_{j=1}^J \sum_{q=1}^Q CJ_{jq} \cdot Gw_{jq} + \sum_{e=1}^E \sum_{s=1}^S CS_{es} \cdot Oc_{es} + \sum_{e=1}^E \sum_{n_2=1}^{N_2} CN_{en_2} \cdot Oc_{en_2} + \sum_{e=1}^E \sum_{q=1}^Q CQ_{eq} \cdot Ow_{eq} + \sum_{s=1}^S \sum_{n_3=1}^{N_3} Cl_{sn_3} \cdot L_{sn_3} + \sum_{k=1}^K \sum_{n_1=1}^{N_1} Cp_{kn_1} \cdot P_{kn_1} + \sum_{q=1}^Q \sum_{m=1}^M Cd_{qm} \cdot D_{qm} \quad (24)$$

- As variáveis R_j , Y_q , W_k , Z_e e V_s são binárias e determinam se certos elementos do modelo estão ativos. Por exemplo, $R_j = 1$ indica que a instalação j está operacional, e $R_j = 0$ caso contrário. As demais variáveis do modelo são contínuas e não negativas, representando valores reais maiores ou iguais a zero. Essas variáveis modelam fluxos, quantidades e outros fatores mensuráveis dentro do sistema.
- As restrições (2)-(7) tratam das limitações de capacidade e demanda de cada instalação na cadeia de suprimentos. Em particular, a restrição (2) limita a quantidade de produtos transportados dos produtores para os centros de distribuição. Já as restrições (3)-(7) garantem que as quantidades enviadas para os centros de processamento, compostagem, fábricas de pistache, centros de extração de óleo e fábricas de cosméticos não ultrapassem as capacidades dessas instalações.

- A quantidade de produtos enviados de qualquer instalação não deve ultrapassar os pedidos recebidos por essa instalação. Consequentemente, a restrição (8) estabelece que a quantidade de produtos expedidos de um centro de processamento deve ser menor ou igual à quantidade recebida por outras instalações. As restrições (9)-(12) definem as quantidades de pistaches de casca aberta, sementes cruas e resíduos gerados durante o processo de descascamento em cada centro de processamento. De forma similar, as restrições (13)-(17) regem os fluxos dentro das fábricas de pistache, centros de extração de óleo, fábricas de cosméticos e centros de compostagem.
- Por fim, para garantir que a demanda dos clientes seja atendida, as restrições (18)-(21) asseguram que as quantidades de produtos entregues aos clientes de pistache, óleo de pistache, cosméticos e composto satisfaçam ou superem suas respectivas demandas.

III. METODOLOGIA

Esta seção apresenta a metodologia utilizada para resolver o problema de otimização, empregando codificação baseada em prioridade [12] e o algoritmo VNS. A codificação baseada em prioridade ordena as variáveis de decisão para explorar o espaço de soluções mantendo a viabilidade, enquanto o VNS alterna entre diferentes estruturas de vizinhança para escapar de ótimos locais. Nossa abordagem inclui operadores de vizinhança personalizados e configurações de parâmetros adequadas.

A. Representação da Solução

Seguindo [2] e [12], utilizamos a codificação baseada em prioridade para representar as soluções. Cada par origem-destino é tratado como um gene, cujas prioridades orientam a construção da árvore de transporte. O processo de decodificação seleciona iterativamente o nó de maior prioridade, conectando-o à alternativa de menor custo, garantindo sempre o cumprimento das restrições de viabilidade.

Diferentemente de [2], que utiliza números reais entre 0 e 1, adotamos números inteiros de 1 a Z , o que melhora a interpretabilidade das soluções e facilita as operações de vizinhança. A codificação inteira oferece uma distinção mais clara entre soluções, o que é especialmente útil em problemas combinatórios, como a otimização de cadeias de suprimentos. Sua eficácia já foi demonstrada em estudos anteriores ([11], [12], [13]).

O processo de decodificação garante a conformidade com as restrições (1)-(21), determinando sequencialmente os fluxos dos produtores para os centros de processamento, fábricas e consumidores, minimizando os custos de transporte. Ajustes são feitos para priorizar as entidades com maior necessidade, assegurando a viabilidade. Da mesma forma, a compostagem e o gerenciamento de resíduos seguem restrições rigorosas de capacidade e demanda para otimizar a distribuição.

A Figura 2 ilustra o processo de decodificação, que inicia com o fluxo de produtos derivados do pistache das fábricas para os consumidores, garantindo o atendimento de todas as

restrições. Os fluxos de óleo e produtos cosméticos seguem princípios semelhantes. Os centros de processamento regulam a alocação do pistache, considerando perdas produtivas e garantindo uma distribuição viável. Os pistaches colhidos são distribuídos proporcionalmente entre fábricas e centros de extração de óleo, priorizando o atendimento da demanda e minimizando custos de transporte. Os fluxos entre produtores e centros de processamento não podem exceder a capacidade de produção, garantindo a viabilidade do sistema. Os fluxos de resíduos e fertilizantes são gerenciados de forma semelhante, respeitando os limites de capacidade de processamento e compostagem, enquanto minimizam os custos.




Figura 2: Etapas de decodificação do fluxo na cadeia de suprimentos

Para a decodificação de cada fluxo da cadeia de suprimentos, utilizamos a função `decodingStep`. Este procedimento corresponde exatamente ao Procedure 1 apresentado na Fig. 3 do artigo [12]. Trata-se de um algoritmo de transporte baseado em prioridades, no qual as unidades de produto são alocadas sucessivamente a partir da fonte ou destino de maior prioridade, de acordo com o vetor cromossomo. Em cada iteração, seleciona-se a fonte ou destino mais prioritário e realiza-se a alocação para o nó adjacente de menor custo, respeitando as restrições de capacidade e demanda. O processo se repete até que todas as demandas sejam atendidas. O fluxo completo de decodificação pode ser visto nos pseudocódigos dos Algoritmos 1 e 2.

B. Busca em Vizinhança Variável (VNS)

O VNS explora o espaço de soluções alterando sistematicamente as estruturas de vizinhança [27]. O algoritmo alterna entre as fases de perturbação (*shaking*) e busca local, aceitando novas soluções apenas se melhorarem a função objetivo. Essa abordagem tem se mostrado eficaz na resolução de problemas de otimização com restrições ([9], [14], [15]).

A implementação do algoritmo VNS utilizado neste estudo está descrita no Algoritmo 3.

C. Estruturas de Vizinhança

Quatro operadores clássicos de vizinhança [7], ilustrados na Figura 3, são utilizados para aumentar a diversidade das

Algorithm 1 Decodificação do cromossomo para a cadeia de suprimentos (Parte 1)

```

1: procedure DECODE(dados)
2:   Entrada: dados estruturados contendo:
3:   - Capacidades e demandas para todas as instalações
4:   - Custos unitários de transporte
5:   - Taxas de perda para cada estágio do processo
6:   - Demandas dos consumidores
7:   - Segmentos de cromossomo ( $S_1, S_2, \dots, S_8$ ) representando prioridades de transporte
8:   Saída:  $custototal$ , variáveis de decisão contínuas ( $X, P, L, O, O_c, G_o, G_r, D, G_w, O_w$ ) e variáveis binárias de abertura ( $U, W, R, V, Y$ )
9:   // Passo 1: Inicializar variáveis e ler dados de entrada
10:   $custototal \leftarrow 0$ 
11:  // Passo 2: Decodificar Fábricas de Pistache → Consumidores de Pistache
12:   $a_1 \leftarrow$  capacidades das fábricas de pistache
13:   $b_1 \leftarrow$  demandas dos consumidores de pistache
14:   $c_1 \leftarrow$  custos de transporte
15:   $(custo1, P) \leftarrow \text{decodingStep}(S_1, a_1, b_1, c_1)$ 
16:   $custototal \leftarrow custototal + custo1$ 
17:  // Passo 3: Decodificar Fábricas de Cosméticos → Consumidores de Cosméticos
18:   $a_2 \leftarrow$  capacidades das fábricas de cosméticos
19:   $b_2 \leftarrow$  demandas dos consumidores de cosméticos
20:   $c_2 \leftarrow$  custos de transporte
21:   $(custo2, L) \leftarrow \text{decodingStep}(S_2, a_2, b_2, c_2)$ 
22:   $custototal \leftarrow custototal + custo2$ 
23:  // Passo 4: Decodificar Centros de Extração de Óleo → (Consumidores de Óleo + Fábricas de Cosméticos)
24:   $a_3 \leftarrow$  capacidades dos centros de extração de óleo
25:   $b_3 \leftarrow$  demandas dos consumidores de óleo e fábricas de cosméticos
26:   $c_3 \leftarrow$  custos de transporte
27:   $(custo3, OO_c) \leftarrow \text{decodingStep}(S_3, a_3, b_3, c_3)$ 
28:  Separar  $OO_c$  em  $O$  (consumidores de óleo) e  $O_c$  (fábricas de cosméticos)
29:   $custototal \leftarrow custototal + custo3$ 
30:  // Passo 5: Decodificar Centro de Processamento → Fábricas de Pistache
31:   $a_4 \leftarrow$  capacidades dos centros de processamento
32:   $b_4 \leftarrow$  demandas ajustadas das fábricas de pistache
33:   $c_4 \leftarrow$  custos de transporte
34:   $(\_, G_o) \leftarrow \text{decodingStep}(S_4, a_4, b_4, c_4)$ 
35:  // Passo 6: Decodificar Centro de Processamento → Centros de Extração de Óleo
36:   $a_5 \leftarrow$  capacidades dos centros de processamento
37:   $b_5 \leftarrow$  demandas ajustadas dos centros de extração de óleo
38:   $c_5 \leftarrow$  custos de transporte
39:   $(\_, G_r) \leftarrow \text{decodingStep}(S_5, a_5, b_5, c_5)$ 
40: end procedure

```

Algorithm 2 Decodificação do cromossomo para a cadeia de suprimentos (Parte 2)

```

1: procedure DECODE(continuação)
2:   // Passo 7: Ajustar demandas nos Centros de Processamento
3:   for cada centro de processamento  $j$  do
4:     Calcular saídas necessárias com base nos fluxos de pistache e óleo
5:     Atualizar  $G_o$  e  $G_r$  para corresponder às capacidades efetivas
6:   end for
7:   // Passo 8: Decodificar Produtores de Pistache → Centros de Processamento
8:    $a_6 \leftarrow$  capacidades dos produtores de pistache
9:    $b_6 \leftarrow$  demandas atualizadas nos centros de processamento
10:   $c_6 \leftarrow$  custos de transporte
11:   $(custo6, X) \leftarrow \text{decodingStep}(S_6, a_6, b_6, c_6)$ 
12:   $custototal \leftarrow custototal + custo6$ 
13:  // Passo 9: Decodificar Centros de Compostagem → Consumidores de Compostagem
14:   $a_7 \leftarrow$  capacidades dos centros de compostagem
15:   $b_7 \leftarrow$  demandas dos consumidores de compostagem
16:   $c_7 \leftarrow$  custos de transporte
17:   $(custo7, D) \leftarrow \text{decodingStep}(S_7, a_7, b_7, c_7)$ 
18:   $custototal \leftarrow custototal + custo7$ 
19:  // Passo 10: Atribuir fluxos de resíduos
20:  Calcular resíduos dos centros de processamento
21:   $a_8 \leftarrow$  capacidades disponíveis dos centros de compostagem
22:   $b_8 \leftarrow$  demandas de resíduos dos centros de processamento e extração de óleo
23:   $c_8 \leftarrow$  custos de transporte
24:   $(\_, O_w) \leftarrow \text{decodingStep}(S_8, a_8, b_8, c_8)$ 
25:  Atualizar  $custototal$ 
26:  // Passo 11: Definir variáveis binárias de abertura
27:   $U \leftarrow$  centros de processamento abertos
28:   $W \leftarrow$  fábricas de pistache abertas
29:   $R \leftarrow$  centros de extração de óleo abertos
30:   $V \leftarrow$  fábricas de cosméticos abertas
31:   $Y \leftarrow$  centros de compostagem abertas
32:  return  $custototal$ , variáveis de decisão e variáveis binárias de abertura
33: end procedure

```

soluções:

- **Swap:** Permuta dois elementos no cromossomo.
- **Reversion:** Inverte a sequência de elementos entre dois índices selecionados [17].
- **Insertion:** Move um elemento para uma nova posição, deslocando os demais conforme necessário [16].
- **Slide:** Remove um elemento, desloca os outros e o reinsere em uma nova posição.

Cada operação é aplicada a um vetor de prioridade se-

Algorithm 3 Busca em Vizinhança Variável (VNS)

Require: Solução inicial x , tamanho máximo da vizinhança

```

 $k_{\max}$ , limite de tempo  $t_{\max}$ 
1: Saída: Melhor solução encontrada  $x^*$ 
2:  $x \leftarrow x$ 
3: repeat
4:    $k \leftarrow 1$ 
5:   repeat
6:      $x' \leftarrow \text{Shake}(x, k)$ 
7:      $x'' \leftarrow \text{LocalSearch}(x')$ 
8:     if  $f(x'') < f(x)$  then
9:        $x \leftarrow x''$ ,  $k \leftarrow 1$ 
10:    else
11:       $k \leftarrow k + 1$ 
12:    end if
13:  until  $k > k_{\max}$ 
14:   $t \leftarrow \text{CpuTime}()$ 
15: until  $t > t_{\max}$ 

```

leccionado aleatoriamente dentro do conjunto de soluções, garantindo a viabilidade e aumentando a eficiência da busca.




Figura 3: Estruturas de vizinhança utilizadas no algoritmo VNS

IV. EXPERIMENTOS COMPUTACIONAIS

O método heurístico proposto foi testado em instâncias de diferentes tamanhos, definidos pelo número de elementos em cada entidade do problema ($I, J, K, E, S, Q, N_1, N_2, N_3$ e M). Os tamanhos testados foram 100, 200, 400, 800 e 1600, resultando em contagens totais de variáveis de 100.500; 401.000; 1.602.000; 6.404.000; e 25.608.000, respectivamente. Entretanto, algoritmos que utilizam codificação baseada em prioridade possuem um número significativamente menor de variáveis, pois consideram apenas as prioridades dos pares fonte-depósito. Nesses casos, as contagens de variáveis foram reduzidas para 1.700; 3.400; 6.800; 13.600; e 27.200.

Os parâmetros das instâncias, como capacidades e demandas, foram gerados aleatoriamente conforme a Tabela 7 de [2]. A abordagem baseada no VNS foi comparada com o GA,

que foi uma das meta-heurísticas evolucionárias utilizadas na referência considerada. O GA utilizou mutações baseadas em troca (*swap-based mutations*) e cruzamentos de subsequências (*subsequence-exchanging crossovers*), com vetores selecionados aleatoriamente, uma população de 100 indivíduos e uma estratégia de seleção por Torneio Binário.

Tanto o VNS quanto o GA foram executados 30 vezes por instância. O critério de parada adotado foi um número máximo de avaliações da função objetivo, definido empiricamente de acordo com a complexidade de cada instância. Os valores foram escolhidos com base em testes preliminares, buscando equilibrar custo computacional e qualidade das soluções obtidas. Especificamente, foram utilizadas 6.250 avaliações para as instâncias de tamanho 100; 12.500 para as de tamanho 200; 25.000 para as de 400; 500.000 para as de 800; e 100.000 para as de 1600. Adicionalmente, o VNS também pode parar a execução quando todos os operadores de vizinhança falharem em melhorar a solução atual.

Os experimentos foram conduzidos em um sistema com Ubuntu 24.04.1 LTS, processador Intel Xeon E3-1240 V2 (8 núcleos) e 32 GB de RAM.

A. Comparação entre VNS e GA

A comparação com o GA segue a metodologia de [2], embora uma correspondência exata não tenha sido possível devido às diferenças no processo de decodificação. A Tabela I apresenta o desempenho médio das 30 melhores soluções obtidas por cada algoritmo. Para instâncias pequenas (tamanho 100), o VNS superou o GA com uma melhoria de 4,48%. À medida que o tamanho do problema aumentou, essa superioridade se manteve e, em alguns casos, foi ainda mais acentuada. O VNS apresentou melhorias variando de 4,48% a 9,87% em relação ao GA nas instâncias maiores, com destaque para o ganho de 9,87% na instância de 200 elementos.

Os boxplots na Fig. 4 ilustram a distribuição das soluções, com diferenças mais significativas nas instâncias maiores. Esses resultados sugerem que o VNS tem um desempenho superior ao GA em problemas de grande escala. Além disso, o GA apresentou tempos de execução muito mais longos, provavelmente devido ao critério de parada adicional do VNS, que leva em consideração o esgotamento dos operadores de vizinhança, enquanto o GA depende de um número fixo de avaliações da função objetivo. Ao mesmo tempo, isso sugere que o VNS pode estar sendo mais eficiente em encontrar boas soluções com um número menor de avaliações.

Os testes estatísticos apresentados na Tabela II reforçam essas observações: nas instâncias 800 e 1600, ambas as distribuições passaram no teste de normalidade de Shapiro-Wilk ($p > 0.05$), permitindo o uso do teste t de Welch, que indicou diferenças estatisticamente significativas ($p < 0,05$). Já nas demais instâncias, pelo menos uma das distribuições não seguiu normalidade, sendo aplicado o teste de Mann-Whitney, que também revelou diferenças significativas. Assim, conclui-se que o VNS foi consistentemente mais eficaz estatisticamente, especialmente à medida que o tamanho do problema aumentou.

Em resumo, embora o GA tenha um desempenho competitivo em instâncias pequenas, sua escalabilidade é limitada. Em contraste, o VNS não apenas obtém soluções superiores, mas também demonstra maior eficiência no tratamento de problemas de grande escala, estabelecendo-se como um método de otimização mais robusto e escalável.

V. CONCLUSÃO

Este estudo apresenta um modelo de otimização para a cadeia de suprimentos de pistache, abordando as complexidades do gerenciamento de produtos e subprodutos ao longo de múltiplas etapas. Ao integrar produção, transporte e operações das instalações, o modelo garante uma alocação eficiente de recursos, respeitando as restrições de capacidade e demanda. Formulado como um problema de Programação Linear Inteira Mista (MILP), ele é resolvido por meio do algoritmo VNS, que explora o espaço de soluções utilizando estruturas de vizinhança como Swap, Reversion, Insertion e Slide.

A análise comparativa demonstra a superioridade do VNS em relação ao GA, tanto em qualidade das soluções quanto em eficiência computacional, especialmente para instâncias de grande escala, onde métodos exatos se tornam inviáveis devido a limitações de tempo e memória.

Pesquisas futuras podem explorar operadores de vizinhança específicos para o problema, aprimorando ainda mais o desempenho do VNS. Além disso, uma abordagem híbrida, combinando VNS com métodos exatos, pode melhorar tanto a precisão quanto a eficiência da solução, tornando a metodologia mais aplicável a diferentes setores.

O código e conjunto de dados utilizados neste estudo estão disponíveis em: https://github.com/raissagd/Pistachio_CLSC.

REFERÊNCIAS

- [1] M. Gen, F. Altıparmak, and L. Lin, "A genetic algorithm for two-stage transportation problem using priority-based encoding," *OR Spectrum*, vol. 28, pp. 337–354, 2006.
- [2] A. Rajabi-Kafshgar, F. Gholian-Jouybari, I. Seyed, and M. Hajiaghahi-Keshteli, "Utilizing hybrid metaheuristic approach to design an agricultural closed-loop supply chain network," *Expert Syst. Appl.*, vol. 217, p. 119504, 2023.
- [3] M. K. Doula, P. Kouloumbis, and K. Elaiopoulos, "Turning wastes into valuable materials: Valorization of pistachio wastes in agricultural sector," in *SYMBIOSIS Int. Conf.*, pp. 19–21, 2014.
- [4] G. Bartzas and K. Komnitsas, "Life cycle analysis of pistachio production in Greece," *Sci. Total Environ.*, vol. 595, pp. 13–24, 2017.
- [5] R. Casper and E. Sundin, "Reverse logistic transportation and packaging concepts in automotive remanufacturing," *Procedia Manuf.*, vol. 25, pp. 154–160, 2018.
- [6] A. Cheraghalipour and E. Roghanian, "A bi-level model for a closed-loop agricultural supply chain considering biogas and compost," *Environ. Dev. Sustain.*, pp. 1–47, 2022.
- [7] K. Devika, A. Jafarian, and V. Nourbakhsh, "Designing a sustainable closed-loop supply chain network based on triple bottom line approach: A comparison of metaheuristics hybridization techniques," *Eur. J. Oper. Res.*, vol. 235, no. 3, pp. 594–615, 2014.
- [8] M. Zohal and H. Soleimani, "Developing an ant colony approach for green closed-loop supply chain network design: a case study in gold industry," *J. Clean. Prod.*, vol. 133, pp. 314–337, 2016.
- [9] E. K. Burke, J. Li, and R. Qu, "A hybrid model of integer programming and variable neighbourhood search for highly-constrained nurse rostering problems," *Eur. J. Oper. Res.*, vol. 203, no. 2, pp. 484–493, 2010.


Tabela I: Comparação entre o algoritmo VNS e uma meta-heurística baseada em população (GA) em termos do valor médio da função objetivo das melhores soluções e do tempo médio de execução.

Instância	Avaliação da função objetivo (média)			Tempo de Execução (média)		
	VNS	GA	Diferença (%)	VNS	GA	Diferença (%)
100	7.44×10^7	7.78×10^7	4.48	369.59s	60,480.38s	197.57
200	1.51×10^8	1.66×10^8	9.87	1,192.69s	23,210.39s	180.45
400	3.12×10^8	3.42×10^8	9.17	3,917.46s	27,590.31s	150.27
800	6.58×10^8	7.08×10^8	7.36	11,512.24s	48,803.09s	123.65
1600	1.36×10^9	1.43×10^9	4.64	17,767s	217,958s	1126.95


Tabela II: Resultados dos testes estatísticos para as instâncias analisadas. Inclui o p-valor do teste de normalidade (Shapiro-Wilk) para o GA e o VNS, e o teste de comparação adequado (Mann-Whitney ou t-teste), com seus respectivos p-valores.

Instância	Shapiro GA (p-valor)	Shapiro VNS (p-valor)	Teste Comparativo	p-valor do Teste
100	0.00039	1.77×10^{-8}	Mann-Whitney	2.80×10^{-7}
200	0.8845	0.0193	Mann-Whitney	2.04×10^{-11}
400	0.0112	0.4451	Mann-Whitney	5.47×10^{-11}
800	0.6487	0.1659	t-teste	4.05×10^{-17}
1600	0.2945	0.5287	t-teste	1.84×10^{-14}


- [10] C. C. Ribeiro, D. Aloise, T. F. Noronha, C. Rocha, and S. Urrutia, "An efficient implementation of a VNS/ILS heuristic for a real-life car sequencing problem," *Eur. J. Oper. Res.*, vol. 191, no. 3, pp. 596–611, 2008.
- [11] M. S. Pishvaei, R. Z. Farahani, and W. Dullaert, "A memetic algorithm for bi-objective integrated forward/reverse logistics network design," *Comput. Oper. Res.*, vol. 37, no. 6, pp. 1100–1112, 2010.
- [12] F. Altıparmak, M. Gen, L. Lin, and T. Paksoy, "A genetic algorithm approach for multi-objective optimization of supply chain networks," *Comput. Ind. Eng.*, vol. 51, no. 1, pp. 196–215, 2006.
- [13] J. Liu, B. Sun, G. Li, and Y. Chen, "An integrated scheduling approach considering dispatching strategy and conflict-free route of AMRs in flexible job shop," *Int. J. Adv. Manuf. Technol.*, vol. 127, no. 3, pp. 1979–2002, 2023.
- [14] A. Imran, S. Salhi, and N. A. Wassen, "A variable neighborhood-based heuristic for the heterogeneous fleet vehicle routing problem," *Eur. J. Oper. Res.*, vol. 197, no. 2, pp. 509–518, 2009.
- [15] K. Fleszar and K. S. Hindi, "An effective VNS for the capacitated p-median problem," *Eur. J. Oper. Res.*, vol. 191, no. 3, pp. 612–622, 2008.
- [16] M. Rabiee, M. Zandieh, and A. Jafarian, "Scheduling of a no-wait two-machine flow shop with sequence-dependent setup times and probable rework using robust meta-heuristics," *Int. J. Prod. Res.*, vol. 50, no. 24, pp. 7428–7446, 2012.
- [17] B. Vahdani and M. Zandieh, "Scheduling trucks in cross-docking systems: Robust meta-heuristics," *Comput. Ind. Eng.*, vol. 58, no. 1, pp. 12–24, 2010.
- [18] M. S. Pishvaei, J. Razmi, and S. A. Torabi, "An accelerated Benders decomposition algorithm for sustainable supply chain network design under uncertainty: A case study of medical needle and syringe supply chain," *Transp. Res. Part E: Logist. Transp. Rev.*, vol. 67, pp. 14–38, 2014.
- [19] S. Ahmadi and S. H. Amin, "An integrated chance-constrained stochastic model for a mobile phone closed-loop supply chain network with supplier selection," *J. Clean. Prod.*, vol. 226, pp. 988–1003, 2019.
- [20] M. Banasik, A. Stanisławska-Sachadyn, and P. Sachadyn, "A simple modification of PCR thermal profile applied to evade persisting contamination," *J. Appl. Genet.*, vol. 57, pp. 409–415, 2016.
- [21] F. Gholian-Jouybari, O. Hashemi-Amiri, B. Mosallanezhad, and M. Hajiaghahi-Keshteli, "Metaheuristic algorithms for a sustainable agri-food supply chain considering marketing practices under uncertainty," *Expert Syst. Appl.*, vol. 213, p. 118880, 2023.
- [22] Statista, "Leading producers of pistachios worldwide in 2022 and 2023," 2023. [Online]. Available: <https://www.statista.com/statistics/933042/global-pistachio-production-by-country/>
- [23] Y. Xie, Y. Sheng, M. Qiu, and F. Gui, "An adaptive decoding biased random key genetic algorithm for cloud workflow scheduling," *Eng. Appl. Artif. Intell.*, vol. 112, p. 104879, 2022.
- [24] Fathollahi-Fard, A. M., & Hajiaghahi-Keshteli, M. (2018). A stochastic multi-objective model for a closed-loop supply chain with environmental considerations. *Applied Soft Computing*, 69, 232–249.
- [25] Hokmabadi, H. (2018). Pistachio wastes in Iran and the potential to recapture them in value chain. *Pistachio and Health Journal*, 1(4), 1–12.
- [26] Dronavalli, S., & Kang, M. S. (2019). Microgametophytic selection for identifying maize with resistance to *Aspergillus spp.* and aflatoxin. *Journal of Crop Improvement*, 33(3), 363–371.
- [27] M. Gendreau and J.-Y. Potvin, Eds., *Handbook of Metaheuristics*, 2nd ed. Springer, 2010.
- [28] P. Hansen, N. Mladenović, and J. A. Moreno Perez, "Variable neighbourhood search: methods and applications," *Ann. Oper. Res.*, vol. 175, pp. 367–407, 2010.
- [29] Campelo, F., & Aranha, C. (2023). Lessons from the Evolutionary Computation Bestiary. *Artificial Life*, 29(4), 421–432. https://doi.org/10.1162/artl_a_00402
- [30] Aranha, C., Camacho Villalón, C. L., Campelo, F., Dorigo, M., Ruiz, R., Sevaux, M., Sörensen, K., & Stützle, T. (2022). Metaphor-based metaheuristics, a call for action: the elephant in the room. *Swarm Intelligence*, 16(1), 1–6.
- [31] Gurobi Optimization, LLC, "Gurobi Optimizer Reference Manual," 2024. [Online]. Available: <https://www.gurobi.com>




(a) $I, J, K, E, S, Q, N1, N2, N3, M = 100$




(b) $I, J, K, E, S, Q, N1, N2, N3, M = 200$



(c) $I, J, K, E, S, Q, N1, N2, N3, M = 400$



(d) $I, J, K, E, S, Q, N1, N2, N3, M = 800$



(e) $I, J, K, E, S, Q, N1, N2, N3, M = 1600$

Figura 4: Boxplots comparando o desempenho do algoritmo VNS e de uma meta-heurística baseada em população (GA) em diferentes tamanhos de problema, com base nos valores da função objetivo.