

Aprimoramento de Metaheurísticas para Otimização da Cadeia de Suprimentos de Pistache

Raissa Gonçalves Diniz * André Costa Batista **

* *Laboratório de Pesquisa Operacional e Sistemas Complexos, Universidade Federal de Minas Gerais, Brasil (e-mail: raissagd@ufmg.br).*

** *Departamento de Engenharia Elétrica, Universidade Federal de Minas Gerais, Av. Antônio Carlos 6627, Belo Horizonte, 31270-010, Minas Gerais, Brasil (e-mail: andre-costa@ufmg.br).*

Resumo: As cadeias de suprimentos desempenham um papel fundamental na indústria agrícola, especialmente no caso de culturas de alto valor, como o pistache, onde uma gestão eficiente pode impulsionar o crescimento econômico e promover a sustentabilidade. Embora pesquisas anteriores tenham explorado estratégias de otimização para essas cadeias, a maioria dos estudos concentra-se no uso de algoritmos populacionais para enfrentar esses desafios. Neste trabalho, propomos a aplicação do algoritmo de Busca em Vizinhança Variável (VNS) e avaliamos seu desempenho em comparação com uma metaheurística populacional, especificamente o Algoritmo Genético (GA). Os resultados mostram que o VNS apresenta consistentemente um desempenho superior ao GA, tanto em termos de eficiência computacional quanto de qualidade das soluções, especialmente em instâncias de maior porte. Esses achados destacam o potencial do método proposto como uma abordagem eficaz para a otimização de cadeias de suprimentos.

Keywords: Otimização de Cadeias de Suprimentos, Metaheurísticas, Busca em Vizinhança Variável, Sustentabilidade

1. INTRODUÇÃO

A agricultura desempenha um papel fundamental no desenvolvimento econômico, contribuindo não apenas para a segurança alimentar, mas também para as exportações e o crescimento industrial. Entre as culturas de alto valor, os pistaches se destacam no comércio internacional, com os Estados Unidos, a Turquia e o Irã liderando a produção global (Statista, 2023). A gestão eficiente de cadeias de suprimentos é essencial para manter a qualidade dos produtos, reduzir impactos ambientais e garantir uma distribuição eficaz. Um dos principais desafios na produção de pistache é o manejo dos subprodutos, como cascas e resíduos da polpa, que, se descartados de forma inadequada, podem comprometer a qualidade do solo e gerar riscos à saúde devido à contaminação por aflatoxinas produzidas por fungos (Dronavalli and Kang, 2019). Estratégias sustentáveis de gestão de resíduos, como compostagem e produção de biogás, têm sido exploradas para mitigar esses problemas, conforme discutido por Cheraghalipour and Roghanian (2022).

Falhas na cadeia de suprimentos exercem impacto significativo tanto na qualidade dos produtos quanto nas operações comerciais. Estudos anteriores, como o de Rajabi-Kafshgar et al. (2023), investigaram técnicas de otimização baseadas em Algoritmos Genéticos (GA) e outras metaheurísticas evolucionárias para a logística do pistache. No entanto, muitas dessas comparações se baseiam apenas nas melhores soluções encontradas, sem uma validação estatística robusta que comprove a superioridade dos re-

sultados. Além disso, ainda há debate sobre a influência real das diferenças entre meta-heurísticas bioinspiradas na qualidade das soluções obtidas.

Neste contexto, o presente estudo propõe a otimização da cadeia de suprimentos do pistache mediante a aplicação da Busca em Vizinhança Variável (VNS), uma heurística reconhecida por sua eficiência na resolução de problemas combinatórios complexos e que requer parametrização mínima. O modelo misto linear proposto por Rajabi-Kafshgar et al. (2023) para a logística direta e reversa foi considerado, incorporando o reaproveitamento de subprodutos como estratégia para minimização de custos e redução de impactos ambientais. Os resultados demonstram que o VNS supera o GA na avaliação da função objetivo, ao mesmo tempo em que obtém soluções competitivas com um tempo computacional significativamente menor em comparação a um método exato.

A estrutura deste artigo organiza-se da seguinte forma: a Seção 2 apresenta a definição do problema, descrevendo a estrutura da cadeia de suprimentos e os objetivos de otimização. A Seção 3 detalha a abordagem heurística, explicando a metodologia VNS e sua implementação. A Seção 4 compara os resultados experimentais entre VNS e GA. Por fim, a Seção 5 apresenta as principais conclusões e direções para pesquisas futuras.

2. DEFINIÇÃO DO PROBLEMA

A rede proposta por Rajabi-Kafshgar et al. (2023), conforme ilustrado na Figura 1, é composta por produtores,

centros de processamento, fábricas de pistache, centros de extração de óleo, centros de compostagem e clientes. Os pistaches são transportados dos pomares para os centros de processamento, onde são transformados em pistaches de casca aberta, sementes cruas e resíduos. Esses produtos são então enviados para fábricas, centros de extração de óleo e centros de compostagem, respectivamente. Os pistaches de casca aberta são torrados, embalados e entregues aos clientes, enquanto o óleo de pistache é fornecido aos clientes de óleo e fábricas de cosméticos. Os resíduos são convertidos em composto para distribuição. Embora o composto seja devolvido aos produtores, idealmente criando um sistema de circuito fechado, o modelo matemático não estabelece uma conexão direta entre os clientes de composto e os produtores que fornecem pistaches aos centros de processamento. Estritamente falando, o modelo matemático de fluxo não implementa um circuito fechado. Em vez disso, interpreta o fluxo de composto para seus respectivos clientes como um feedback, mesmo que esses clientes não estejam necessariamente vinculados às variáveis associadas aos produtores. Abordagens semelhantes foram adotadas em outros estudos (Pishvae et al., 2010; Ahmadi and Amin, 2019; Banasik et al., 2016), e a implementação rigorosa de um circuito de feedback poderia ser uma direção promissora para pesquisas futuras.

O problema linear misto visa minimizar os custos totais (1), incluindo custos de abertura, transporte e produção, sob as seguintes restrições de capacidade e demanda, não tolerando escassez (ver mais detalhes sobre as variáveis na Tabela 5 de Rajabi-Kafshgar et al. (2023)):

$$\min z_1 + z_2 + z_3 \quad (1)$$

$$\text{s.t.:} \quad \sum_{j=1}^J X_{ij} \leq Cpa_i, \quad \forall i \in I \quad (2)$$

$$\sum_{i=1}^I X_{ij} \leq Cpu_j \times U_j, \quad \forall j \in J \quad (3)$$

$$\sum_{e=1}^E Ow_{eq} + \sum_{j=1}^J Gw_{jq} \leq Cpy_q \times Y_q, \quad \forall q \in Q \quad (4)$$

$$\sum_{j=1}^J Go_{jk} \leq Cpw_k \times W_k, \quad \forall k \in K \quad (5)$$

$$\sum_{j=1}^J Gr_{je} \leq Cpr_e \times R_e, \quad \forall e \in E \quad (6)$$

$$\sum_{e=1}^E O_{en_2} \leq Cpv_s \times V_s, \quad \forall s \in S \quad (7)$$

$$\sum_{k=1}^K Go_{jk} + \sum_{e=1}^E Gr_{je} + \sum_{q=1}^Q Gw_{jq} \leq \sum_{i=1}^I X_{ij}, \quad \forall j \in J \quad (8)$$

$$\sum_{k=1}^K Go_{jk} = (1 - \beta) \sum_{i=1}^I X_{ij} \theta_1, \quad \forall j \in J \quad (9)$$




Figura 1. Cadeia de Suprimentos de PistacFhe proposta

$$\sum_{e=1}^K Gr_{je} = (1 - \beta) \sum_{i=1}^I X_{ij} \theta_2, \quad \forall j \in J \quad (10)$$

$$\sum_{q=1}^Q Gw_{jq} = \sum_{i=1}^I X_{ij} \theta_3, \quad \forall j \in J \quad (11)$$

$$\theta_1 + \theta_2 + \theta_3 = 1 \quad (12)$$

$$\sum_{n_1=1}^{N_1} P_{kn_1} \leq \sum_{j=1}^J Go_{jk} \times \gamma_k, \quad \forall k \in K \quad (13)$$

$$\sum_{n_2=1}^{N_2} O_{en_2} + \sum_{s=1}^S Oc_{es} \leq \sum_{j=1}^J Gr_{je} \times (1 - \lambda), \quad \forall e \in E \quad (14)$$

$$\sum_{q=1}^Q Ow_{eq} \leq \sum_{j=1}^J Gr_{je} \times \lambda, \quad \forall e \in E \quad (15)$$

$$\sum_{n_3=1}^{N_3} L_{sn_3} \leq \sum_{e=1}^E Oc_{es} \times \gamma_s, \quad \forall s \in S \quad (16)$$

$$\sum_{m=1}^M D_{qm} \leq \left(\sum_{j=1}^J Gw_{jq} + \sum_{e=1}^E Ow_{eq} \right) \times \gamma_q, \quad \forall q \in Q \quad (17)$$

$$\sum_{k=1}^K P_{kn_1} \geq Dp_{n_1}, \quad \forall n_1 \in N_1 \quad (18)$$

$$\sum_{e=1}^E O_{en_2} \geq Du_{n_2}, \quad \forall n_2 \in N_2 \quad (19)$$

$$\sum_{s=1}^S L_{sn_3} \geq Ds_{n_3}, \quad \forall n_3 \in N_3 \quad (20)$$

$$\sum_{q=1}^Q D_{qm} \leq Dc_m, \quad \forall m \in M \quad (21)$$

- A função objetivo (1) minimiza os custos totais da cadeia de suprimentos, incluindo custos de abertura, transporte e produção. Os custos são divididos em três componentes: z_1 (22), z_2 (23), e z_3 (24), que representam os custos de abertura de instalações, transporte e produção, respectivamente, conforme mostrado nas seguintes equações:

$$z_1 = \sum_{j=1}^J Fu_j \cdot U_j + \sum_{q=1}^Q Fy_q \cdot Y_q + \sum_{k=1}^K Fw_k \cdot W_k + \sum_{e=1}^E Fr_e \cdot R_e + \sum_{s=1}^S Fv_s \cdot V_s \quad (22)$$

$$z_2 = \sum_{i=1}^I \sum_{j=1}^J CI_i \cdot X_{ij} + \sum_{j=1}^J \sum_{k=1}^K Cu_{1j} \cdot Go_{jk} + \sum_{j=1}^J \sum_{e=1}^E Cu_{2j} \cdot Gr_{je} + \sum_{q=1}^Q \sum_{m=1}^M Cy_q \cdot D_{qm} + \sum_{k=1}^K \sum_{n_1=1}^{N_1} Cw_k \cdot P_{kn_1} \quad (23)$$

$$z_3 = \sum_{i=1}^I \sum_{j=1}^J CX_{ij} \cdot X_{ij} + \sum_{j=1}^J \sum_{k=1}^K CK_{jk} \cdot Go_{jk} + \sum_{j=1}^J \sum_{q=1}^Q CJ_{jq} \cdot Gw_{jq} + \sum_{e=1}^E \sum_{s=1}^S CS_{es} \cdot Oc_{es} + \sum_{e=1}^E \sum_{q=1}^Q CQ_{eq} \cdot Ow_{eq} \quad (24)$$

- As variáveis R_j , Y_q , W_k , Z_e e V_s são binárias e determinam se certos elementos do modelo estão ativos. Por exemplo, $R_j = 1$ indica que a instalação j está operacional, e $R_j = 0$ caso contrário. As demais variáveis do modelo são contínuas e não negativas, representando valores reais maiores ou iguais a zero. Essas variáveis modelam fluxos, quantidades e outros fatores mensuráveis dentro do sistema.
- As restrições (2)-(7) tratam das limitações de capacidade e demanda de cada instalação na cadeia de suprimentos. Em particular, a restrição (2) limita a quantidade de produtos transportados dos produtores para os centros de distribuição. Já as restrições (3)-(7) garantem que as quantidades enviadas para os centros de processamento, compostagem, fábricas de pistache, centros de extração de óleo e fábricas de cosméticos não ultrapassem as capacidades dessas instalações.
- A quantidade de produtos enviados de qualquer instalação não deve ultrapassar os pedidos recebidos por essa instalação. Consequentemente, a restrição (8) estabelece que a quantidade de produtos expedidos de um centro de processamento deve ser menor ou igual à quantidade recebida por outras instalações. As restrições (9)-(12) definem as quantidades de pistaches de casca aberta, sementes cruas e resíduos gerados durante o processo de descascamento em cada centro de processamento. De forma similar, as restrições (13)-(17) regem os fluxos dentro das fábricas de pistache, centros de extração de óleo, fábricas de cosméticos e centros de compostagem.
- Por fim, para garantir que a demanda dos clientes seja atendida, as restrições (18)-(21) asseguram que as quantidades de produtos entregues aos clientes

de pistache, óleo de pistache, cosméticos e composto satisfaçam ou superem suas respectivas demandas.

3. METODOLOGIA

Esta seção apresenta a metodologia utilizada para resolver o problema de otimização, empregando codificação baseada em prioridade (Gen et al., 2006) e o algoritmo de Busca em Vizinhança Variável (VNS). A codificação baseada em prioridade ordena as variáveis de decisão para explorar o espaço de soluções mantendo a viabilidade, enquanto a VNS alterna entre diferentes estruturas de vizinhança para escapar de ótimos locais. Nossa abordagem inclui operadores de vizinhança personalizados e configurações de parâmetros adequadas.

3.1 Representação da Solução

Seguindo Rajabi-Kafshgar et al. (2023) e Gen et al. (2006), utilizamos a codificação baseada em prioridade para representar as soluções. Cada par origem-destino é tratado como um gene, cujas prioridades orientam a construção da árvore de transporte. O processo de decodificação seleciona iterativamente o nó de maior prioridade, conectando-o à alternativa de menor custo, garantindo sempre o cumprimento das restrições de viabilidade.

Diferentemente de Rajabi-Kafshgar et al. (2023), que utiliza números reais entre 0 e 1, adotamos números inteiros de 1 a Z para melhorar a interpretabilidade e facilitar as operações de vizinhança. A eficácia dessa codificação já foi demonstrada em otimização de cadeias de suprimentos (Pishvae et al., 2010; Altiparmak et al., 2006; Liu et al., 2023).

O processo de decodificação garante a conformidade com as restrições (1)-(21), determinando sequencialmente os fluxos dos produtores para os centros de processamento, fábricas e consumidores, minimizando os custos de transporte. Ajustes são feitos para priorizar as entidades com maior necessidade, assegurando a viabilidade. Da mesma forma, a compostagem e o gerenciamento de resíduos seguem restrições rigorosas de capacidade e demanda para otimizar a distribuição.

A Figura 2 ilustra o processo de decodificação, que inicia com o fluxo de produtos derivados do pistache das fábricas para os consumidores, garantindo o atendimento de todas as restrições. Os fluxos de óleo e produtos cosméticos seguem princípios semelhantes. Os centros de processamento regulam a alocação do pistache, considerando perdas produtivas e garantindo uma distribuição viável. Os pistaches colhidos são distribuídos proporcionalmente entre fábricas e centros de extração de óleo, priorizando o atendimento da demanda e minimizando custos de transporte. Os fluxos entre produtores e centros de processamento não podem exceder a capacidade de produção, garantindo a viabilidade do sistema. Os fluxos de resíduos e fertilizantes são gerenciados de forma semelhante, respeitando os limites de capacidade de processamento e compostagem, enquanto minimizam os custos.

3.2 Busca em Vizinhança Variável (VNS)

A Busca em Vizinhança Variável (VNS) explora o espaço de soluções alterando sistematicamente as estruturas de




Figura 2. Etapas de decodificação do fluxo de produtos na cadeia de suprimentos

vizinhança (Gendreau et al., 2010). O algoritmo alterna entre as fases de perturbação (*shaking*) e busca local, aceitando novas soluções apenas se melhorarem a função objetivo. Essa abordagem tem se mostrado eficaz na resolução de problemas de otimização com restrições (Imran et al., 2009; Fleszar and Hindi, 2008; Burke et al., 2010).

A implementação do algoritmo VNS utilizado neste estudo está descrita no Algoritmo 1.

Algorithm 1 Busca em Vizinhança Variável (VNS)

Require: Solução inicial x , tamanho máximo da vizinhança $k_{\max}$, limite de tempo $t_{\max}$
1: Saída: Melhor solução encontrada x^*
2: $x \leftarrow x$
3: **repeat**
4: $k \leftarrow 1$
5: **repeat**
6: $x' \leftarrow \text{Shake}(x, k)$
7: $x'' \leftarrow \text{LocalSearch}(x')$
8: **if** $f(x'') < f(x)$ **then**
9: $x \leftarrow x''$, $k \leftarrow 1$
10: **else**
11: $k \leftarrow k + 1$
12: **end if**
13: **until** $k > k_{\max}$
14: $t \leftarrow \text{CpuTime}()$
15: **until** $t > t_{\max}$

3.3 Estruturas de Vizinhança

Quatro operadores clássicos de vizinhança (Devika et al., 2014), ilustrados na Figura 3, são utilizados para aumentar a diversidade das soluções:

- **Swap:** Permuta dois elementos no cromossomo.
- **Reversion:** Inverte a sequência de elementos entre dois índices selecionados (Vahdani and Zandieh, 2010).
- **Insertion:** Move um elemento para uma nova posição, deslocando os demais conforme necessário (Rabiee et al., 2012).
- **Slide:** Remove um elemento, desloca os outros e o reinsere em uma nova posição.

Cada operação é aplicada a um vetor de prioridade selecionado aleatoriamente dentro do conjunto de soluções,

garantindo a viabilidade e aumentando a eficiência da busca.




Figura 3. Estruturas de vizinhança utilizadas no algoritmo VNS

4. EXPERIMENTOS COMPUTACIONAIS

O método heurístico proposto foi testado em instâncias de diferentes tamanhos, definidos pelo número de elementos em cada entidade do problema ($I, J, K, E, S, Q, N_1, N_2, N_3$ e M). Os tamanhos testados foram 100, 200, 400, 800 e 1600, resultando em contagens totais de variáveis de 100.500; 401.000; 1.602.000; 6.404.000; e 25.608.000, respectivamente. Entretanto, algoritmos que utilizam codificação baseada em prioridade possuem um número significativamente menor de variáveis, pois consideram apenas as prioridades dos pares fonte-depósito. Nesses casos, as contagens de variáveis foram reduzidas para 1.700; 3.400; 6.800; 13.600; e 27.200.

Os parâmetros das instâncias, como capacidades e demandas, foram gerados aleatoriamente conforme a Tabela 7 de Rajabi-Kafshgar et al. (2023). A abordagem baseada em VNS foi comparada com um Algoritmo Genético (GA), que foi uma das meta-heurísticas evolucionárias utilizadas na referência considerada. O GA utilizou mutações baseadas em troca (*swap-based mutations*) e cruzamentos de subsequências (*subsequence-exchanging crossovers*), com vetores selecionados aleatoriamente, uma população de 100 indivíduos e uma estratégia de seleção por Torneio Binário.

Tanto o VNS quanto o GA foram executados 30 vezes por instância, com um critério de parada de 100.000 avaliações da função objetivo. Os experimentos foram conduzidos em um sistema com Ubuntu 24.04.1 LTS, processador Intel Xeon E3-1240 V2 (8 núcleos) e 32 GB de RAM.

4.1 Comparação entre VNS e GA

A comparação com o GA segue a metodologia de Rajabi-Kafshgar et al. (2023), embora uma correspondência exata não tenha sido possível devido às diferenças no processo de decodificação. A Tabela 1 apresenta o desempenho médio das 30 melhores soluções obtidas por cada algoritmo. Para instâncias pequenas (100 elementos), VNS e GA apresentaram desempenho semelhante, com uma melhoria de apenas 0,71% para o VNS. No entanto, em instâncias maiores, o VNS superou consistentemente o GA, alcançando melhorias entre 3,4% e 5,3%.

Os boxplots na Fig. 4 ilustram a distribuição das soluções, destacando diferenças significativas nos casos de 800 e 1600 instâncias. Os valores de p obtidos no teste t para amostras independentes (teste de Welch) para essas instâncias são inferiores a 0,05, indicando que as diferenças observadas são estatisticamente significativas, considerando normalidade e variâncias desiguais. Esses resultados sugerem que o VNS tem um desempenho significativamente superior ao GA em problemas de grande escala do ponto de vista estatístico. Além disso, o GA apresentou tempos de execução mais longos, provavelmente devido ao aumento dos custos computacionais de suas operações evolutivas à medida que o tamanho do problema crescia.

Em resumo, embora o GA tenha um desempenho competitivo em instâncias pequenas, sua escalabilidade é limitada. Em contraste, o VNS não apenas obtém soluções superiores, mas também demonstra maior eficiência no tratamento de problemas de grande escala, estabelecendo-se como um método de otimização mais robusto e escalável.

5. CONCLUSÃO

Este estudo apresenta um modelo de otimização para a cadeia de suprimentos de pistache, abordando as complexidades do gerenciamento de produtos e subprodutos ao longo de múltiplas etapas. Ao integrar produção, transporte e operações das instalações, o modelo garante uma alocação eficiente de recursos, respeitando as restrições de capacidade e demanda. Formulado como um problema de Programação Linear Inteira Mista (MILP), ele é resolvido por meio do algoritmo Variable Neighborhood Search (VNS), que explora o espaço de soluções utilizando estruturas de vizinhança como Swap, Reversion, Insertion e Slide.

A análise comparativa demonstra a superioridade do VNS em relação aos Algoritmo Genético (GA), tanto em qualidade das soluções quanto em eficiência computacional, especialmente para instâncias de grande escala, onde métodos exatos se tornam inviáveis devido a limitações de tempo e memória.

Pesquisas futuras podem explorar operadores de vizinhança específicos para o problema, aprimorando ainda mais o desempenho do VNS. Além disso, uma abordagem híbrida, combinando VNS com métodos exatos, pode melhorar tanto a precisão quanto a eficiência da solução, tornando a metodologia mais aplicável a diferentes setores.

O código e conjunto de dados utilizados neste estudo estão disponíveis em: https://github.com/raissagd/Pistachio_CLSC.

REFERÊNCIAS

- Ahmadi, S. and Amin, S.H. (2019). An integrated chance-constrained stochastic model for a mobile phone closed-loop supply chain network with supplier selection. *Journal of cleaner production*, 226, 988–1003.
- Altıparmak, F., Gen, M., Lin, L., and Paksoy, T. (2006). A genetic algorithm approach for multi-objective optimization of supply chain networks. *Computers & industrial engineering*, 51(1), 196–215.
- Banasik, M., Stanisławska-Sachadyn, A., and Sachadyn, P. (2016). A simple modification of pcr thermal profile applied to evade persisting contamination. *Journal of Applied Genetics*, 57, 409–415.
- Burke, E.K., Li, J., and Qu, R. (2010). A hybrid model of integer programming and variable neighbourhood search for highly-constrained nurse rostering problems. *European Journal of Operational Research*, 203(2), 484–493.
- Cheraghali, A. and Roghanian, E. (2022). A bi-level model for a closed-loop agricultural supply chain considering biogas and compost. *Environment, Development and Sustainability*, 1–47.
- Devika, K., Jafarian, A., and Nourbakhsh, V. (2014). Designing a sustainable closed-loop supply chain network based on triple bottom line approach: A comparison of metaheuristics hybridization techniques. *European journal of operational research*, 235(3), 594–615.
- Dronavalli, S. and Kang, M.S. (2019). Microgametophytic selection for identifying maize with resistance to aspergillus spp. and aflatoxin. *Journal of Crop Improvement*, 33(3), 363–371.
- Fleszar, K. and Hindi, K.S. (2008). An effective vns for the capacitated p-median problem. *European Journal of Operational Research*, 191(3), 612–622.
- Gen, M., Altıparmak, F., and Lin, L. (2006). A genetic algorithm for two-stage transportation problem using priority-based encoding. *OR spectrum*, 28, 337–354.
- Gendreau, M., Potvin, J.Y., et al. (2010). *Handbook of metaheuristics*, volume 2. Springer.
- Imran, A., Salhi, S., and Wassan, N.A. (2009). A variable neighborhood-based heuristic for the heterogeneous fleet vehicle routing problem. *European Journal of Operational Research*, 197(2), 509–518.
- Liu, J., Sun, B., Li, G., and Chen, Y. (2023). An integrated scheduling approach considering dispatching strategy and conflict-free route of amrs in flexible job shop. *The International Journal of Advanced Manufacturing Technology*, 127(3), 1979–2002.
- Pishvaei, M.S., Farahani, R.Z., and Dullaert, W. (2010). A memetic algorithm for bi-objective integrated forward/reverse logistics network design. *Computers & operations research*, 37(6), 1100–1112.
- Rabiee, M., Zandieh, M., and Jafarian, A. (2012). Scheduling of a no-wait two-machine flow shop with sequence-dependent setup times and probable rework using robust meta-heuristics. *International Journal of Production Research*, 50(24), 7428–7446.
- Rajabi-Kafshgar, A., Gholian-Jouybari, F., Seyedi, I., and Hajiaghahi-Keshteli, M. (2023). Utilizing hybrid metaheuristic approach to design an agricultural closed-loop supply chain network. *Expert Systems with Applications*, 217, 119504.
- Statista (2023). Leading producers of pistachios worldwide in 2022 and 2023. URL <https://www.statista.com/statistics/933042/global-pistachio-production-by-country/>. Accessed: 2023-10-05.
- Vahdani, B. and Zandieh, M. (2010). Scheduling trucks in cross-docking systems: Robust meta-heuristics. *Computers & Industrial Engineering*, 58(1), 12–24.




Figura 4. Boxplots comparando o desempenho do algoritmo VNS e de uma meta-heurística baseada em população (Algoritmo Genético) em diferentes tamanhos de problema, com base nos valores da função objetivo.

Tabela 1. Comparação entre o algoritmo VNS e uma meta-heurística baseada em população (Algoritmo Genético) em termos do valor médio da função objetivo das melhores soluções e do tempo médio de execução.

Instância	Avaliação da função objetivo (média)			Tempo de Execução (média)	
	VNS	GA	Diferença (%)	VNS	GA
100	7.41×10^6	7.46×10^6	0.71	241s	6,595s
200	1.50×10^8	1.55×10^8	3.37	714s	14,349s
400	3.08×10^8	3.24×10^8	5.31	2,016s	33,941s
800	6.57×10^8	6.92×10^8	5.26	5,538s	82,687s
1600	1.36×10^9	1.43×10^9	4.64	17,767s	217,958s